

Detección de gestos y lengua de signos

Alfons Baiges, Héctor Berger, Gonzalo Maurín

Abstract— Lorem ipsum dolor sit amet, consectetur adipiscing elit. Curabitur quis fermentum orci. Aliquam sodales varius blandit. Vestibulum congue tortor a fringilla venenatis. Nam magna ex, fringilla eu porta facilisis, consequat quis orci. Vivamus ut mattis metus. Interdum et malesuada fames ac ante ipsum primis in faucibus. Maecenas a orci at nibh so-dales condimentum. Orci varius natoque penatibus et mag-nis dis parturient montes, nascetur ridiculus mus.

Duis interdum nisi id sem dictum rhoncus. Duis vitae ante tincidunt, tempor diam quis, tincidunt lorem. Etiam sit amet nisi tempus sapien auctor vestibulum ac eu purus. Curabitur a suscipit urna, sit amet facilisis erat. Morbi iaculis vestibulum tortor, quis varius justo mollis ut. Pellentesque placerat felis pretium, maximus ex quis, rutrum nisi. Sed quis imperdiet nunc. Donec euismod ipsum sed urna semper posuere. Nunc id gravida enim. Suspendisse tortor lectus, tempus tincidunt tellus at, mattis tincidunt tortor. Morbi finibus ultrices bibendum. Morbi ac ipsum eu erat consectetur convallis at.

Keywords—Visión por Computador, Reconocimiento de Gestos, Deep learning, OTSU & canny edge detection, Lengua de signos ASL MNIST, Skeleton-Based Dynamic Hand Gesture Recognition.

1 INTRODUCCIÓN

El reconocimiento de gestos es un campo muy importante dentro de la visión por computador, con variedad de aplicaciones entre humano-ordenador, accesibilidad y sistemas de comunicación no verbal. Nos centraremos en la interpretación del lenguaje de señas y el análisis de gestos en tiempo real para realizar comandos en una aplicación. Para ello nos hemos planteado cuatro etapas diferentes por las cuales iremos evolucionando progresivamente desde métodos clásicos hasta un modelo de aprendizaje profundo.

- Reconocimiento de manos: En la fase inicial nuestro objetivo principal es la detección de manos sin ningún significado concreto, solo para poder ser capaces de diferenciar manos del resto de la imagen con técnicas clásicas.
- Detección de gestos: en esta etapa nos fijaremos en como detectar gestos concretos, con técnicas como Harris y LBP/HOG.
- Detección con Deep Learning: continuaremos esta vez con una detección de señas en ASL (American Sign Language), ya que hemos encontrado un dataset MNIST preprocesado.
- Detección de gestos con aprendizaje profundo y información esquelética: finalmente, utilizaremos un dataset de gestos (tanto propio como externo) para entrenar un modelo de gestos dinámicos. Además de programar comandos sencillos en un programa para realizarlos en tiempo real.

El objetivo de este proyecto, a parte del punto final anteriormente mencionado, es a medida que vamos avanzando en las diferentes etapas, ir aprendiendo de detección de objetos (en este caso una mano) a partir de imagen, tanto con técnicas más clásicas como con las más nuevas.

2 ESTADO DEL ARTE

El campo del reconocimiento de movimiento de manos se encuentra hoy en día en un estado muy avanzado, con una amplia variedad de estrategias y enfoques para abordar este problema. A lo largo del tiempo, estas técnicas han experimentado una evolución significativa, pasando de métodos más simples y limitados, basados en reglas y sensores físicos, a enfoques mucho más sofisticados. En la actualidad, destacan especialmente las soluciones basadas en Deep Learning, que permiten analizar grandes volúmenes de datos y captar patrones complejos con gran precisión, mejorando notablemente el rendimiento y la adaptabilidad de estos sistemas en diferentes aplicaciones.

Técnicas que consideramos más importantes:

2.1 Apartado físico

Uso de algún elemento físico para facilitar el reconocimiento de la mano

- Guante: utiliza un guante con sensores para capturar el movimiento de la mano y la posición la palma y los dedos para poder la extremidad. Esta opción tiene la limitación de que es necesaria una conexión física con el ordenador que se este utilizando para la lectura de datos.
- Color: detectan la piel mediante modelos de color o utilizan marcadores de colores específicos para identificar la mano dentro de la imagen. Estos métodos se basan generalmente en la segmentación por color, ya sea en espacios como RGB, HSV o YCbCr, lo que permite aislar regiones que coinciden con tonos de piel o con colores previamente definidos para los marcadores. Gracias a su simplicidad, son fáciles de implementar y requieren un bajo coste computacional, lo que los hace adecuados para aplicaciones en tiempo real o sistemas con recursos limitados.

2.2 Apartado digital

- Esqueleto: extraen puntos clave de la mano y de sus articulaciones, lo que permite representar de manera estructurada la posición y el movimiento de cada dedo y de la palma. Estos puntos, facilitan la construcción de un modelo geométrico de la mano que resulta especialmente útil para expresar y analizar gestos de forma precisa. A partir de esta información, es posible calcular características relevantes como la orientación de las articulaciones, la distancia entre puntos clave, los ángulos formados entre los dedos y las trayectorias de movimiento. Estas propiedades permiten capturar tanto la forma estática de la mano como su dinámica en el tiempo, lo que mejora significativamente la capacidad de los sistemas para reconocer gestos complejos.
- Apariencia: analizan la forma visual de la mano a partir de características extraídas directamente de la imagen, como la detección de bordes, contornos y siluetas. Estos métodos se centran en la información global de la mano, capturando su forma y estructura sin necesidad de modelos internos

complejos. Gracias a ello, suelen ser eficientes computacionalmente y funcionan bien en tiempo real, lo que los hace adecuados para aplicaciones interactivas.

- **Movimiento:** detectan gestos a partir de cambios en los fotogramas, son útiles para gestos dinámicos con un fondo estable, pero si el fondo es en movimiento son incapaces de detectarlo. Este enfoque permite identificar la dinámica del gesto, es decir, cómo se desplaza la mano a lo largo del tiempo, lo que resulta especialmente útil para reconocer gestos dinámicos que implican trayectorias o movimientos continuos.
- **Profundidad:** usan cámaras específicas para obtener información 3D, mejoran la segmentación pero es necesario el hardware específico. Con este método se puede conseguir información como la distancia entre mano y cámara, lo que permite una mejora de segmentación.
- **Modelos 3D:** buscan reconstruir la pose completa de la mano en el espacio tridimensional, teniendo en cuenta la posición y orientación de dedos y articulaciones, gracias a esto permiten una representación más precisa y detallada del gesto, sin embargo, son más complejos computacionalmente y muchos de ellos necesitan de sensores adicionales (cámaras de profundidad...).

2.3 Uso de redes neuronales

- **Deep Learning:** los modelos basados en deeplearning usan redes neuronales, especialmente redes neuronales convolucionales (CNN) para aprender automáticamente representaciones relevantes a partir de los datos de entrada, eliminando la necesidad de diseñar manualmente las características. Estos modelos son actualmente superiores en cuanto al reconocimiento de gestos, tanto en imágenes como video, gracias a su capacidad para capturar patrones espaciales y, en casos, temporales. Sin embargo, estos métodos requieren grandes volúmenes de datos etiquetados para su entrenamiento, así como un elevado coste computacional, lo que puede dificultar su implementación.

3 PROPUESTA

El material que vamos a utilizar para realizar nuestros experimentos se basa en dos datasets de *kaggle*, y un pequeño dataset creado a partir de unos videos grabados por nosotros. Haremos Data Augmentation en este último.

3.1 ASL MNIST

El primer dataset que usaremos es el MNIST (por sus siglas en inglés, Modified National Institute of Standards and Technology database) no oficial del alfabeto del lenguaje de señas americano [3].

El Lenguaje de Señas MNIST se encuentra en formato Formato CSV, con etiquetas y valores de píxeles en filas individuales. Cada fila es una imagen en escala de grises de una mano haciendo un gesto. Este base de datos representa 24 clases de letras (excluyendo J y Z que requieren movimiento). Por lo tanto, cada caso representa una etiqueta (0-25) como un mapa 1-1 para cada letra del alfabeto A-Z (sin 9=J ni 25=Z). Tenemos 27.455 casos de entreno y 7172 casos para test, susceptible a modificaciones.

3.2 Información Esqueletal

El segundo dataset de *kaggle* [4] se divide en dos ya que es multi-modal, en imágenes de gestos con las manos: cercanas al infrarrojo y información esquelética. Nos parecen más relevantes el segundo tipo de datos, ya que es una técnica más actualizada y interesante sobre la que trabajar. Este dataset son realmente 15 gestos diferentes (palma hacia arriba, números, pulgar arriba, etc), 6 veces cada, de 15 sujetos diferentes (5 mujeres y 10 hombres). Tenemos $15 * 15 * 6 = 1350$ casos para entrenar y testear nuestro modelo.

3.3 Dataset Propio

Construiremos un dataset propio a partir de videos captados con la webcam integrada en nuestros portátiles. Nos centraremos en 5 gestos con movimiento para realizar 5 comandos diferentes, recopilaremos estos datos con información esquelética como en el anterior dataset pero quedándonos con los principales atributos necesarios. La idea es crear 75 casos reales, 25 gestos (5 de cada tipo) por cada integrante del grupo, posteriormente a partir de recortes y giros aumentar el volumen a mínimo 250 casos.

4 EXPERIMENTOS, RESULTADOS Y ANÁLISIS

Lorem ipsum dolor sit amet, con-sectetur adipiscing elit.

4.1 Experimento

Sed in leo rhoncus, gravida elit vel, tristique quam. Nullam auctor mi in tortor mollis ullamcorper. Duis mattis nisl purus. Maecenas posuere libero sem, a vulputate erat elei-fend eu. Proin a iaculis enim. Suspendisse potenti. Vestibulum egestas sed erat ac porttitor. Vestibulum a est risus. Suspendisse potenti. Donec eleifend dui erat, vel blandit nisl dignissim sit amet. Quisque et odio elit. Cras bibendum felis vitae neque tincidunt ornare.

Integer maximus, diam eu tristique tincidunt, tellus sem sagittis urna, ac viverra nisi nibh nec lectus. Morbi mollis tincidunt ligula, in vestibulum lectus condimentum eu. Cras nec porttitor nibh. Fusce bibendum eu nunc nec eleifend. Morbi id nulla accumsan nisi suscipit tempus. Donec mollis sem enim. Praesent hendrerit dignissim tellus nec imperdiet.



Fig. 1: Escena on es troba amagat el subjecte d'anàlisi. Podem veure a la dreta una andròmina amb forma de chubby robot, precursor del gènere meka i de l'aspirador roomba.

4.2 Resultado

Nunc dictum ipsum quis egestas scelerisque. Vestibulum rutrum tempor posuere. Praesent varius libero odio, ac bibendum arcu tempus quis. Pellentesque habitant morbi tristique senectus et

netus et malesuada fames ac turpis egestas. Sed eget ex risus. Integer metus velit, viverra ac fringilla sit amet, laoreet eget lacus. Nulla rutrum mollis elit et maximus. Nulla sed aliquet elit. Sed libero justo, porta ut vulputate eget, suscipit faucibus sem. Sed at quam ut justo vestibulum vehicula non sed ligula. Nulla facilisi. Curabitur pulvinar, dolor amet ultrices porttitor, odio nisl tincidunt magna, cras lobortis metus tristique erat placerat, sed dapibus elit tellus vel mauris.

Pellentesque ex dolor, ullamcorper et tempus ac, feugiat vel ligula. Cras ut sagittis nisi. Nunc mauris turpis, dignissim ut lorem vitae, suscipit vulputate mi. Curabitur at elit neque. Nam ornare vel turpis tempus eleifend. Morbi faucibus risus eros, sit amet congue lectus tristique a. Aenean ut egestas ex. Vivamus consequat eu odio sit amet mattis. Nullam pretium sodales eleifend. Fusce fermentum risus ac nisi interdum, ornare vestibulum metus laoreet. Cras finibus nisi eu bibendum viverra. Maecenas vel nulla sed nibh suscipit iaculis id imperdiet elit. Mauris a enim enim. Etiam vestibulum odio ac elit iaculis sollicitudin. In mollis in erat ut malesuada.



Fig. 2: Detecció de l'andròmina.

x	sin(x)	cos(x)	tan(x)	sec(x)	cosec(x)
30°	0.5000	0.8660	0.5774	1.1547	2.0000
45°	0.7071	0.7071	1.0000	1.4142	1.4142
60°	0.8660	0.5000	1.7321	2.0000	1.1547

Taula 1: Raons trigonomètriques per diferents valors d'angles.

4.3 Análisis

El rendimiento lo miraremos con los casos de test(diferentes a los del entreno para evitar overfitting) en el caso del aprendizaje profundo, siendo aceptable cuando pase u 90% de aciertos. También nos interesaría crear un dataset de validación para ver si generaliza el modelo, o por contrario no. En el caso de las técnicas clásicas usaremos las mismas estadísticas para la clasificación, pero para la detección y coincidencia de puntos de interés miraremos la repetitividad y la precisión.

5 CONCLUSIONES

Aliquam erat volutpat. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Donec ut sapien nec turpis placerat maximus. Quisque port-titor nulla ex, vel finibus nisi commodo in. Vivamus fringilla diam eget est egestas, id hendrerit leo tincidunt. Mauris tin-cidunt iaculis ornare. Curabitur pulvinar, dolor amet ultrices porttitor, odio nisl tincidunt magna, sed dapibus elit tellus vel mauris. Proin faucibus scelerisque orci vitae aliquet. Nulla ullamcorper tincidunt nisl, sit amet mollis mi pretium sit amet. Fusce sagittis vehicula nibh, ut pulvinar magna ves-tibulum eget. Praesent vulputate accumsan eros sed portti-tor.

Quisque consectetur justo a mi porta, id varius nisi posue-re. Morbi tristique orci nec dolor aliquet venenatis. Integer malesuada tincidunt dignissim. Cras lobortis metus tristique erat placerat, nec rutrum justo pretium. Integer faucibus aliquet commodo. Integer non quam nec lectus. Sed in leo rhoncus, gravida elit vel, tristique quam. Nullam auctor mi in tortor mollis ullamcorper.

Nunc dictum ipsum quis egestas scelerisque. Vestibulum rutrum tempor posuere. Praesent varius libero odio, ac bibe-ndum arcu tempus quis. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Sed eget ex risus. Integer metus velit, viverra ac fringilla sit amet, laoreet eget lacus. Nulla rutrum mollis elit et maximus. Nulla sed aliquet elit. Sed libero justo, porta ut vulputate eget, suscipit faucibus sem. Sed at quam ut justo vestibulum vehicula non sed ligula.

Nulla facilisi. Curabitur pulvinar, dolor amet ultrices porttitor, odio nisl tincidunt magna, cras lobortis metus tristique erat placerat, sed dapibus elit tellus vel mauris. Phasellus vitae purus gravida, rutrum ante vel, vestibulum mauris.

REFERÈNCIES

- [1] M. Oudah, A. Al-Naji, J. Chahl. (23 de Julio de 2020). "Hand Gesture Recognition Based on Computer Vision: A Review of Techniques". <https://pmc.ncbi.nlm.nih.gov/articles/PMC8321080/>
- [2] Q. De Smedt, H. Wannous and J. -P. Vandeborre. "Skeleton-Based Dynamic Hand Gesture Recognition," 2016 IEEE Conference on Computer Vision and Pattern Recognition Workshops (CVPRW), Las Vegas, NV, USA, 2016, pp. 1206-1214, doi: 10.1109/CVPRW.2016.153. keywords: Gesture recognition;Three-dimensional displays;Skeleton;Shape;Cameras;Sensors;Databases
- [3] P. Tecle. (2017). "Sign Language MNIST Dataset". Kaggle Datasets. <https://www.kaggle.com/datasets/datamunge/sign-language-mnist>
- [4] GTI-UPM Group. (2019). "Multi-modal Hand Gesture Recognition Dataset". Kaggle Datasets. <https://www.kaggle.com/datasets/gti-upm/multimodhandgestrec>
- [5] Rifa Tasfia. (2023). "Article from International Journal of Electrical and Computer Engineering". <https://ijece.iaescore.com/index.php/IJECE/article/view/34455/17578>